

Hospidata SUS — Grupo 54

Metodologia, regras de tratamento de dados e principais insights da clusterização de municípios de São Paulo

Este documento resume as decisões técnicas, regras de tratamento de dados e principais insights obtidos na análise de clusterização de municípios de São Paulo, com base em dados de internações hospitalares (SIHSUS), estabelecimentos de saúde (CNES) e população (IBGE).

1. Fontes de dados utilizadas

Base	Conteúdo	Escopo
STG_SIHSUS	Internações hospitalares (dias de permanência, óbito, valor da internação, município de residência)	Nacional (filtrado para SP no tratamento)
STG_CNES / STG_CNES_JSON	Estabelecimentos de saúde (tipo de unidade, se possui atendimento hospitalar, centro cirúrgico etc.)	Amostra de São Paulo
STG_IBGE	Nome e população de cada município	Somente municípios de São Paulo (UF 35)

Como o IBGE cobre apenas municípios de SP, o SIHSUS foi restrito a **município de residência com código iniciado em '35'** antes do cruzamento — sem isso, pacientes de outros estados internados em SP geravam linhas sem população/nome (join vazio).

2. Regras de tratamento aplicadas

2.1 Tratamento de valores nulos e inconsistências

- Municípios sem **população** (falha no cruzamento com IBGE) foram removidos da base final (dados.dropna(subset=['POPULACAO'])).
- QTD_ESTAB_HOSPITALARES** nulo foi tratado como 0 (fillna(0)) — ausência de registro no CNES para aquele município não significa dado inválido, apenas nenhum estabelecimento hospitalar identificado.
- No cruzamento SQL, NVL(c.qtd_estab_hospitalares, 0) e NULLIF(populacao, 0) evitam erro de divisão por zero e tratam município sem correspondência no CNES como zero estabelecimentos (em vez de excluir a linha).
- Município de residência (SIHSUS) restrito a UF 35 (São Paulo), batendo com o escopo do IBGE.

2.2 Correção de viés — Razão Observado/Esperado

A métrica bruta de **internações por mil habitantes** distorce municípios pequenos: qualquer volume baixo de internações já gera uma taxa desproporcional. Para corrigir isso, foi calculada uma taxa média geral de internação (ponderada pela população total do estado) e, a partir dela, o número de internações *esperadas* para cada município dado seu tamanho populacional. A **razão observado/esperado** (internações reais ÷ internações esperadas) substituiu a taxa bruta nas features do modelo: valores acima de 1 indicam internação acima do esperado pela população; abaixo de 1, indicam abaixo do esperado.

Importante: por carregarem o mesmo viés populacional, QTD_INTERNACOES (valor bruto) e INTERNACOES_POR_MIL_HAB foram excluídas das features de clusterização — apenas razao_obs_esperado (já normalizada) foi usada.

2.3 Features e modelo de clusterização

- **Features utilizadas:** PERMANENCIA_MEDIA, TAXA_MORTALIDADE_PCT, QTD_ESTAB_HOSPITALARES, razao_obs_esperado.
- **Pipeline:** padronização (StandardScaler) seguida de redução de dimensionalidade (PCA, 2 componentes) — variância explicada de aproximadamente 57,3%.
- **Escolha de k:** Método do Cotovelo (Elbow Method), testado de k=1 a k=9.
- **Modelo final:** K-Means com k=3, semente aleatória fixa (random_state=1224) para reprodutibilidade.

3. Perfil dos clusters (médias por grupo)

Cluster	Municípios	Permanência média (dias)	Mortalidade média (%)	Estab. hospitalares (méd.)	Razão obs/esperado
0	400	4,35	5,94	0,83	1,17
1	152	6,07	12,22	4,14	1,00
2	93	6,75	4,69	0,55	1,96

- **Cluster 0 (400 municípios, majoritário):** perfil "padrão" — baixa mortalidade, poucos estabelecimentos hospitalares, razão obs/esperado levemente acima de 1. Municípios pequenos/médios sem grandes desvios.
- **Cluster 1 (152 municípios):** maior mortalidade média (12,2%) e mais estabelecimentos hospitalares (4,1 em média) — perfil de municípios com maior complexidade/gravidade dos casos internados, possivelmente polos regionais de atendimento de maior porte.
- **Cluster 2 (93 municípios):** razão obs/esperado quase 2x — municípios com internação bem acima do esperado pela população, mas mortalidade e estrutura hospitalar mais baixas que o Cluster 1. Inclui os outliers de maior destaque (Jaci, Divinolândia).

4. Análise de outliers — principais insights

A detecção de outliers foi feita por distância euclidiana ao centróide do próprio cluster no espaço reduzido do PCA, marcando como outlier quem está a mais de 2 desvios-padrão da distância média do seu grupo. Os 24 pontos identificados se dividem em **três categorias com significados bem diferentes** — essa distinção é o principal insight da análise.

4.1 Outliers por sobrecarga real (achado principal)

Jaci e Divinolândia — razão observado/esperado acima de 5x (5,32 e 5,36), com populações médias (7.613 e 11.158 hab.) e volume de internação muito acima do esperado. É o sinal mais forte de possível anomalia real: pode indicar um polo regional que atrai pacientes de municípios vizinhos, concentração de um problema de saúde pública local, ou inconsistência no registro do município de residência na base do SUS. **Esses dois municípios são o achado central da análise de outliers.**

4.2 Outliers estatísticos por amostra pequena (ressalva metodológica)

Borá (66,7% de mortalidade) e **Pedrinhas Paulista** (44,4%) parecem alarmantes, mas são municípios muito pequenos (907 e 2.804 habitantes) com poucas internações no total (3 e 9). Nesse volume, um único óbito já representa uma fração enorme — é o clássico "problema dos números pequenos" em estatística de saúde, não um indicador real de crise sanitária. **Trata-se de uma ressalva metodológica, não de um alerta.**

4.3 Outlier por escala (não é alerta)

São Paulo (capital) aparece como outlier do Cluster 1, mas por um motivo diferente: sua razão observado/esperado é 0,91 — praticamente dentro do esperado pela população. O que a torna um outlier geometricamente é a escala absoluta (11,4 milhões de habitantes, 46.260 internações, 227 estabelecimentos), muito acima de qualquer outro município, o que a afasta no espaço do PCA mesmo com métricas relativas normais. **Outlier estatístico não é sinônimo de outlier problemático.**

4.4 Outliers residuais do Cluster 0 (comportamento típico do grupo)

A maior parte dos 24 pontos (ex.: Gabriel Monteiro, Pedranópolis, Brejo Alegre, entre outros) são municípios pequenos, sem estabelecimento hospitalar e com mortalidade zero. Eles aparecem como outlier porque o Cluster 0 tem baixíssima variância interna (é um grupo muito homogêneo), então qualquer pequeno desvio já ultrapassa o limite estatístico. Na prática, representam o comportamento típico de cidade pequena sem hospital — **não indicam risco, apenas o limite da sensibilidade do método de detecção.**

Em vez de tratar os 24 pontos como uma lista única de "municípios preocupantes", faz mais sentido separá-los em três categorias (sobrecarga real / ressalva estatística / efeito de escala) — isso reflete maior rigor analítico e evita alarmismo com casos que são apenas artefatos estatísticos.

5. Tabela completa de outliers identificados

Município	Cluster	População	Internações	Perman. média	Mortal. (%)	Estab. hosp.	Razão obs/esp.
Jaci	2	7.613	180	24,41	1,11	1	5,32
Divinolândia	2	11.158	266	17,95	1,50	1	5,36
São Paulo	1	11.451.999	46.260	6,44	6,87	227	0,91
Borá	1	907	3	6,00	66,67	0	0,74

Município	Cluster	População	Internações	Perman. média	Mortal. (%)	Estab. hosp.	Razão obs/esp.
Pedrinhas Paulista	1	2.804	9	3,78	44,44	0	0,72
Rubiácea	1	2.700	8	14,88	12,50	0	0,67
Gabriel Monteiro	0	2.763	3	1,67	0,00	0	0,24
Pedranópolis	0	2.787	8	1,00	12,50	0	0,65
Brejo Alegre	0	2.565	4	2,00	0,00	0	0,35
Nova Castilho	0	1.062	2	2,00	0,00	0	0,42
Quadra	0	3.405	10	1,60	0,00	0	0,66
Rifaina	0	4.049	26	1,31	0,00	0	1,44
São João de Iracema	0	1.846	10	1,30	0,00	0	1,22
Bento de Abreu	0	2.606	4	2,75	0,00	0	0,35
Meridiano	0	4.572	15	2,80	13,33	0	0,74
Águas de São Pedro	0	2.780	19	2,05	0,00	0	1,54
Poloni	0	5.592	43	3,88	0,00	0	1,73
Flora Rica	0	1.487	5	2,40	0,00	0	0,76
Motuca	0	4.034	21	2,10	0,00	0	1,17
Buritizal	0	4.356	15	2,47	0,00	0	0,77
Onda Verde	0	4.771	34	3,09	0,00	0	1,60
Alumínio	0	17.301	33	3,36	6,06	0	0,43
Guzolândia	0	4.246	28	2,82	0,00	0	1,48
General Salgado	0	10.312	81	3,46	1,23	1	1,77

Outlier definido por distância euclidiana $>$ média + 2 desvios-padrão da distância ao centróide do próprio cluster, no espaço de 2 componentes principais (PCA).